

TP5 : Clustering

Objectif

L'objectif de ce TP est de mettre en pratique les algorithmes de classification non supervisée:

- K-means
 - PAM
 - Classification Hiérarchique
 - DBSCAN
-

1. Exploration de la base de données IRIS

La base de données IRIS contient cinq variables :

- Sepal.Length
- Sepal.Width
- Petal.Length
- Petal.Width
- Species (3 classes : setosa, versicolor, virginica)

Taper la commande suivante pour plus d'informations:

```
str(iris)
```

Exercice 1

1. Appliquer l'analyse en composantes principales (commande `prcomp`) sur iris (stocker le résultat dans un objet nommé `iris_pca`).
 2. Visualiser les données en utilisant les deux premières composantes principales et en les colorant selon `Species`.
 3. Comment interpréter la séparation entre les classes?
-

2. Clustering par K-means

Exercice 2

1. Appliquer la standardization sur la base des données `iris` (stocker le résultat dans un objet nommé `iris_std`).
 2. Appliquer l'algorithme des K-Moyennes (K-Means) en utilisant la commande `kmeans` avec `k = 3` sur les données normalisées.
 3. Visualiser le résultat (nuage de points coloré par cluster).
 4. Le clustering correspond-il aux vraies classes ? Pourquoi ?
-

3. Clustering par PAM (Partitioning Around Medoids)

Exercice 3

Faire la même chose avec l'algorithme PAM (commande `pam` de la bibliothèque `cluster`).

4. Classification Hiérachique

Exercice 4


Faire la même chose avec l'algorithme de la classification hiérarchique (commande `hclust`):

- Utiliser la commande `dist` pour créer la matrice des distances.
 - Utiliser la commande `cutree` pour couper l'arbre et obtenir 3 clusters.
-

5. Bases de données synthétiques

Description :

- `Data1_1` : 5 clusters sphériques, 1000 points
- `Data1_2` : 3 clusters sphériques densités différentes, 900 points
- `Data1_3` : 9 clusters, 3000 points
- `Data1_4` : 9 clusters formes variées, 3030 points
- `Data1_5` : 2 clusters + 5% de bruit, 2100 points



Utiliser la commande suivante pour charger les fichiers csv dans R:

```
library(readr)
library(dplyr)
data1_1 <- read_csv("path/to/Data1_1.csv") %>%
  mutate(class = as.factor(class))
summary(data1_1)
```

Exercice 5

1. Appliquer `kmeans`, `pam` et `hclust` (en choisissant le niveau de coupure adéquat) et tracer les quatres graphiques (avec la classification originale) pour chaque dataset.
 2. Le clustering correspond-il aux vraies classes ? Pourquoi ?
 3. Appliquer DBSCAN (commande `dbSCAN` de la bibliothèque `dbSCAN`) sur chaque dataset.
-